

SQL B HADOOP

SQL to MapReduce, PIG vs Hive vs Impala, Hive QL







1. Может ли стадия Reduce начаться до завершения стадии Мар? Почему?





1. Может ли стадия Reduce начаться до завершения стадии Map? Почему?

Петров	Геннадий			
Андреев	Андрей			
Сидоркин	Александр			
Петров	Николай			
Петров	Олег			





1. Может ли стадия Reduce начаться до завершения стадии Мар? Почему?

Петров	Геннадий	Андреев	Андрей
Андреев	Андрей	Петров	Геннадий
Сидоркин	Александр	Петров	Николай
Петров	Николай	Петров	Олег
Петров	Олег	Сидоркин	Александр





1. Может ли стадия Reduce начаться до завершения стадии Map? Почему?

Петров	Геннадий		Андреев	Андрей		Андреев	Андрей
Андреев	Андрей		Петров	Геннадий		Петров	Геннадий
Сидоркин	Александр		Петров	Николай		Петров	Николай
Петров	Николай		Петров	Олег		Петров	Олег
]	C	A		Сидоркин	Александр
Петров	Олег		Сидоркин	Александр	,		





6. На кластере лежит датасет, в котором ключами является іd сотрудника и дата, а значением размер выплаты. Руководитель поставил задачу рассчитать среднюю сумму выплат по каждому сотруднику за последний месяц. В маппере вы отфильтровали старые записи и отдали ключ-значение вида: id-money. А в редьюсере суммировали все входящие числа и поделили результат на их количество. Но вам в голову пришла идея оптимизировать расчет, поставив этот же редьюсер и в качестве комбинатора, тем самым уменьшив шафл данных. Можете ли вы так сделать? Если да, то где можно было допустить ошибку? Если нет, то что должно быть на выходе комбинатора?

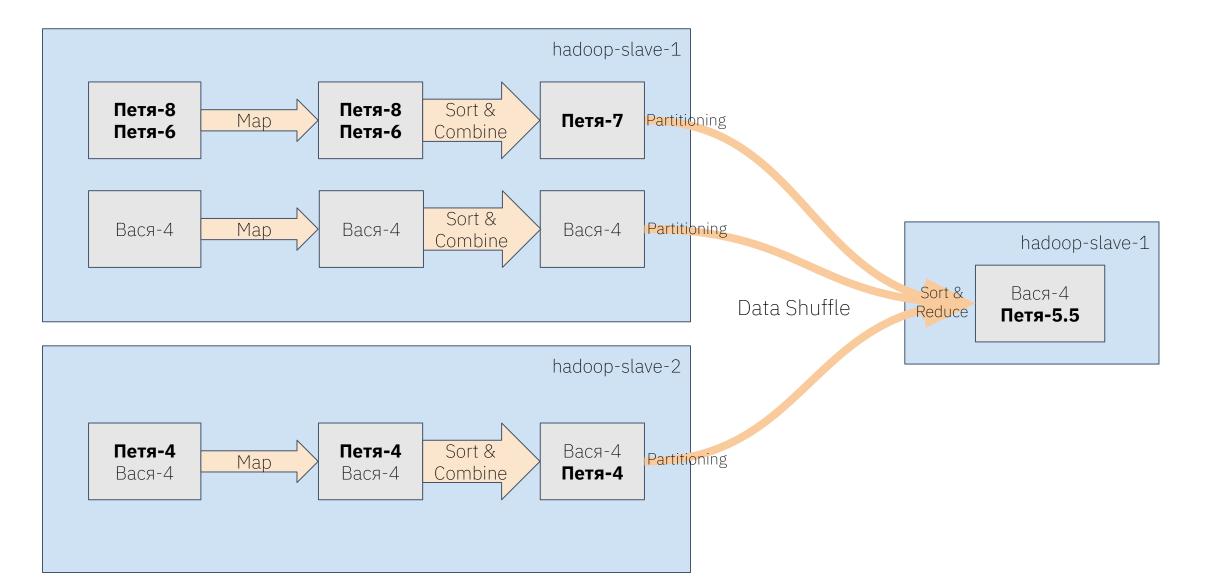
Мы не можем так сделать, так как количество начислений на каждой из нод кластера может быть разным. В таком случае, на комбинаторах будет потеряно это значение и среднее арифметическое будет неправильным.

Но мы можем написать комбинатор, который будет для каждого сотрудника отдавать пару значений: общая сумма и количество начислений. После чего на редьюсере объеденить все суммы и разделить на общее количество начислений.





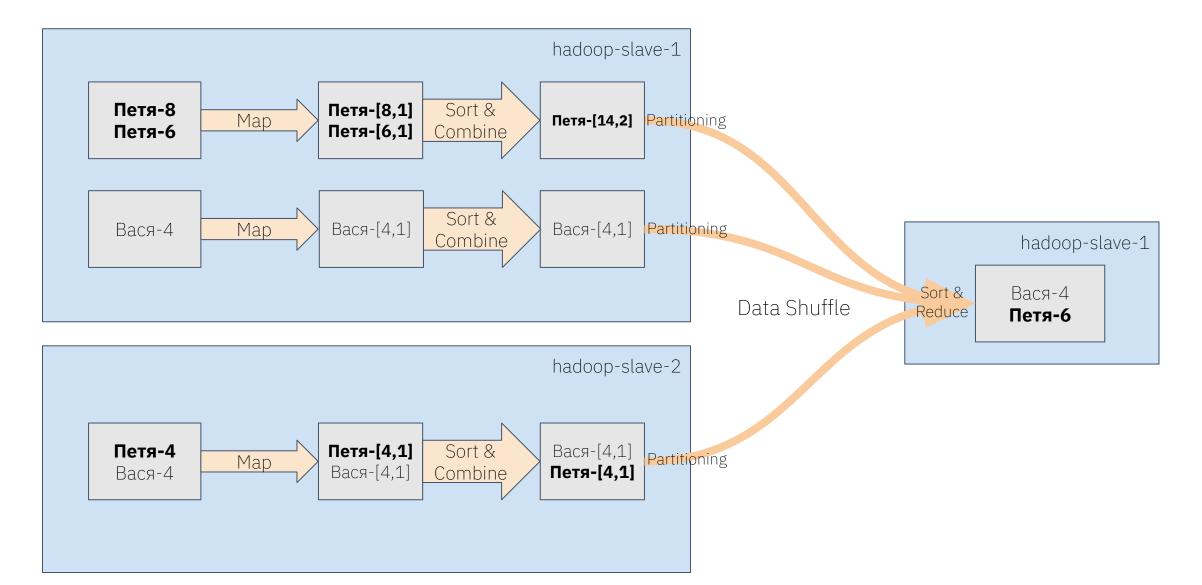
РАЗБОР ПРАКТИЧЕСКОГО ЗАДАНИЯ: ОШИБКА







РАЗБОР ПРАКТИЧЕСКОГО ЗАДАНИЯ: ПРАВИЛЬНО





ИСТОРИЯ HIVE



Facebook начал использовать Hadoop в качестве решения для хранения непрерывно растущего потока данных





Facebook начал использовать Hadoop в качестве решения для хранения непрерывно растущего потока данных



Сложные запросы к данным в Наdоор требуют написания нескольких последовательных МарReduce задач на сотни строк кода и следить за их стабильностью



Facebook начал использовать
Наdоор в качестве решения для
хранения непрерывно
растущего потока данных



Не все пользователи данных владеют Java или другим ЯП на достаточном уровне, чтобы написать задачу

Сложные запросы к данным в Наdоор требуют написания нескольких последовательных МарReduce задач на сотни строк кода и следить за их стабильностью



Facebook начал использовать Hadoop в качестве решения для хранения непрерывно растущего потока данных



Не все пользователи данных владеют Java или другим ЯП на достаточном уровне, чтобы написать задачу

Сложные запросы к данным в Наdоор требуют написания нескольких последовательных МарReduce задач на сотни строк кода и следить за их стабильностью Зато все, кому нужно работать с данными, владеют SQL





Facebook начал использовать Hadoop в качестве решения для хранения непрерывно растущего потока данных



Не все пользователи данных владеют Java или другим ЯП на достаточном уровне, чтобы написать задачу

Был разработан инструмент, который реализовал концепцию таблиц и колоночного представления данных поверх MapReduce, чтобы с ним можно было работать, как с SQL

Сложные запросы к данным в Наdоор требуют написания нескольких последовательных МарReduce задач на сотни строк кода и следить за их стабильностью Зато все, кому нужно работать с данными, владеют SQL









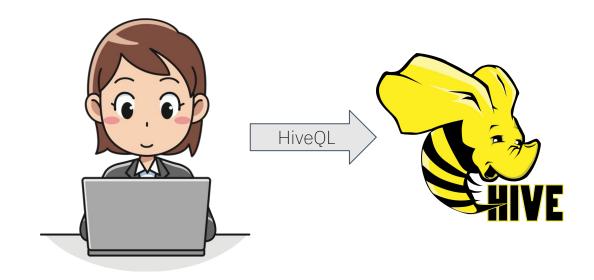
Hive это система хранения данных, предоставляющая средства для работы и анализа больших датасетов, хранящихся в HDFS

Hive использует язык запросов HiveQL, который является подмножеством SQL











Hive преобразует HiveQL запрос в серию MapReduce задач, выполняемых в кластере







Клиентские приложения

Hive поддерживает несколько типов клиентских приложений, которые могут быть написаны на разных языках программирования



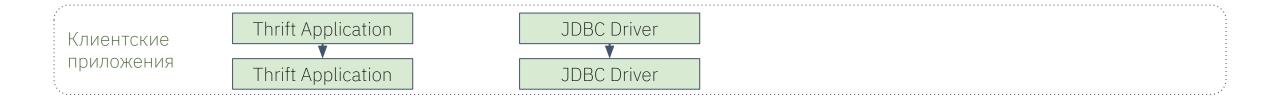
Клиентские приложения Thrift Application

Thrift Application

Thrift Application

Thrift это RPC фреймворк, позволяющий вызывать удаленные методы других приложений

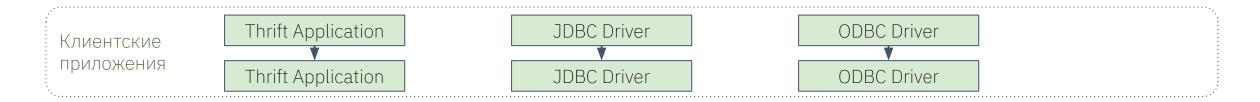




JDBC — Java Database Connectivity

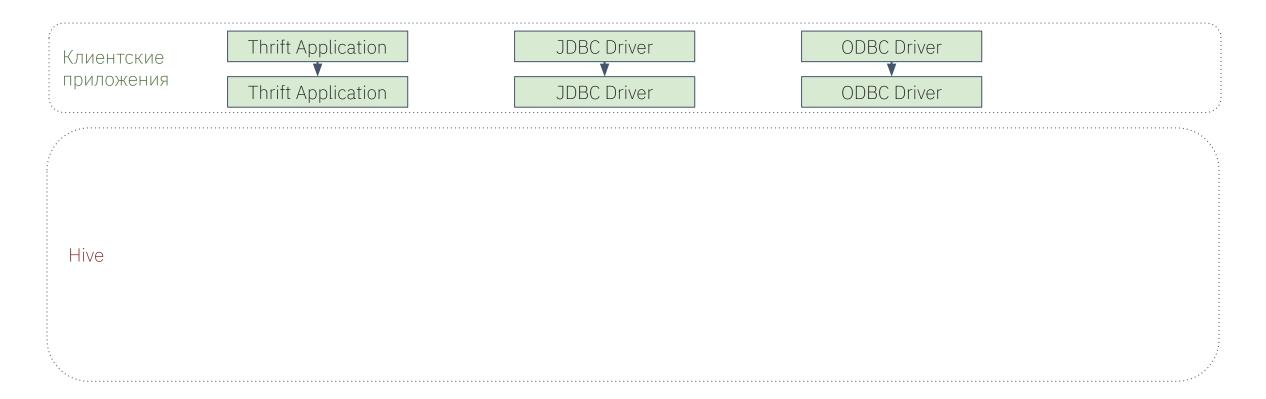
Позволяет JVM приложениям через JDBC драйвер работать с различными базами данных, отправляя на них SQL запросы и обрабатывающая ответы





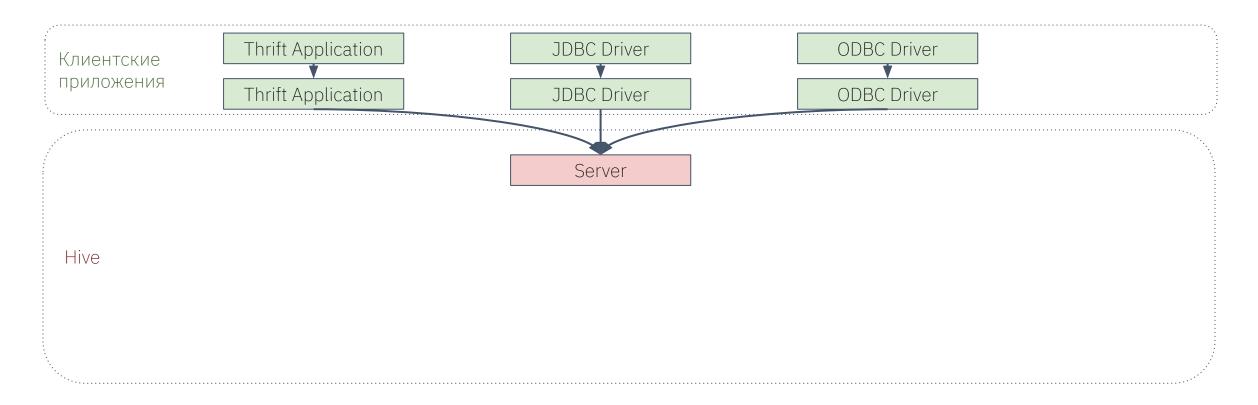
ODBC — Open Database Connectivity
Аналогичная JDBC разработка от Microsoft





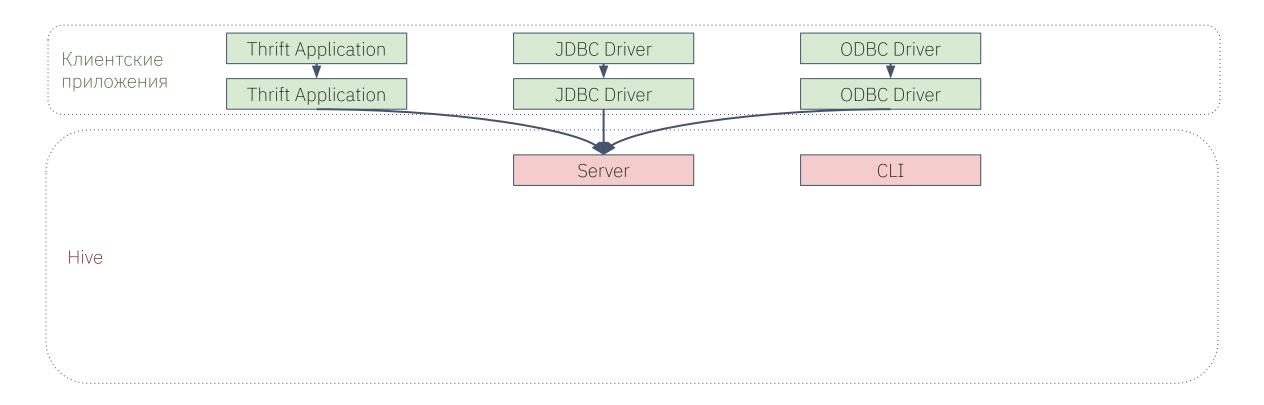
Hive состоит из нескольких сервисов, обеспечивающих его работу





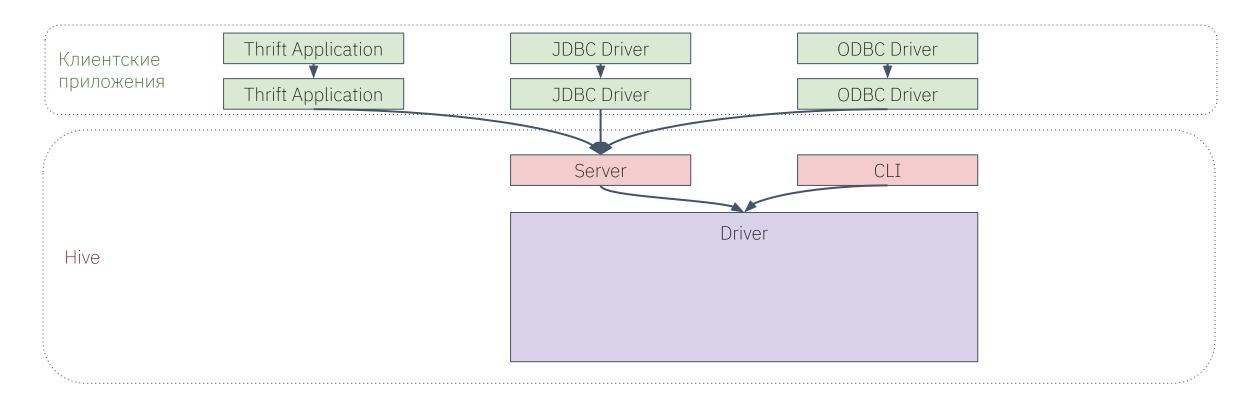
Все клиентские запросы отправляются на сервер





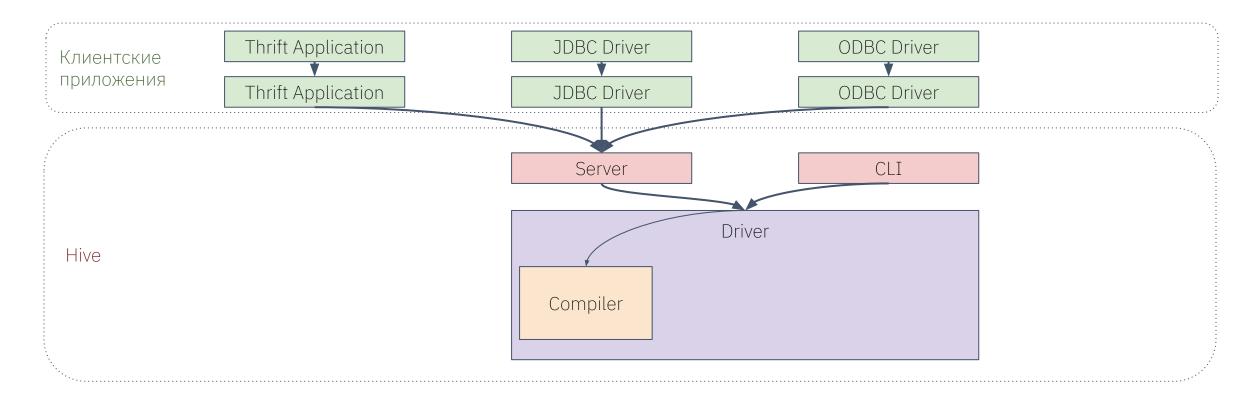
Интерактивная оболочка позволяет обрабатывать запросы напрямую





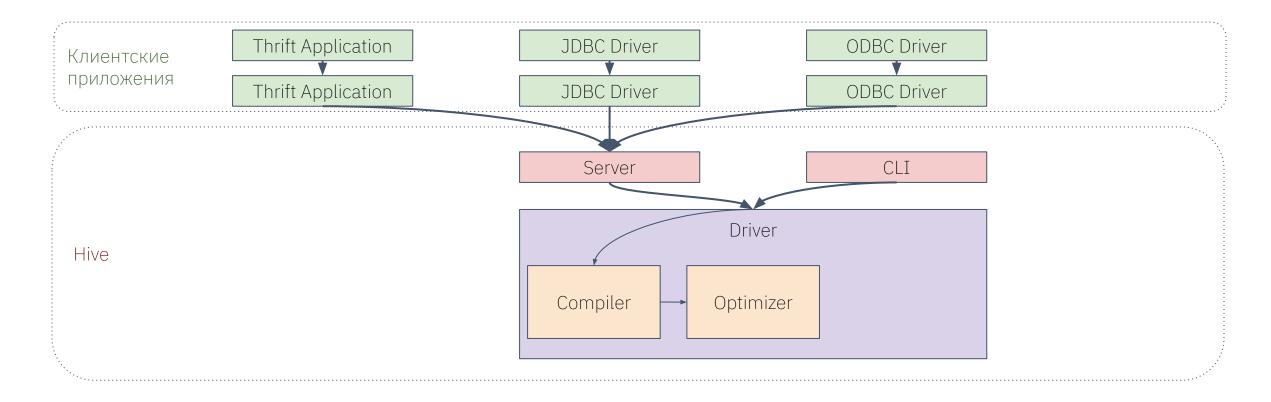
Драйвер отвечает за обработку и исполнение запросов и состоит из трех компонентов





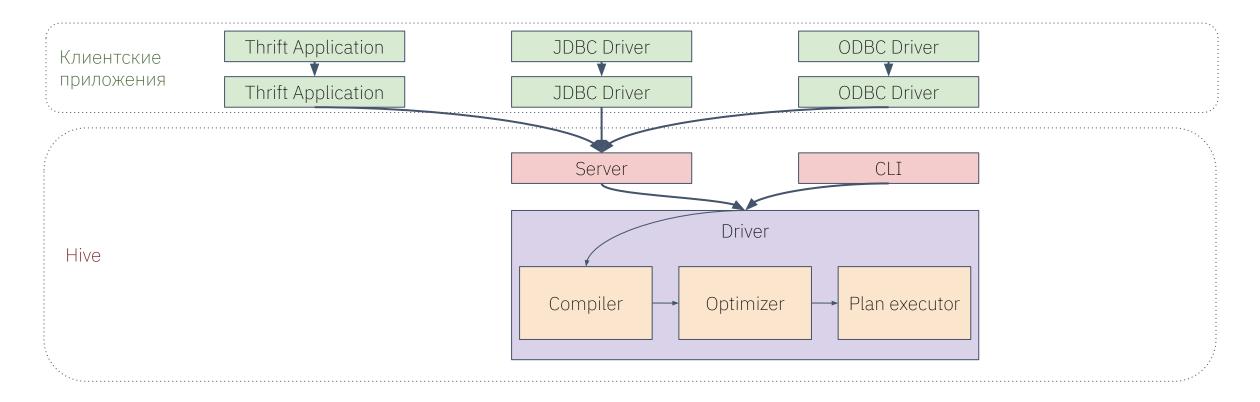
Компилятор анализирует HiveQL запрос и проверяет его на корректность





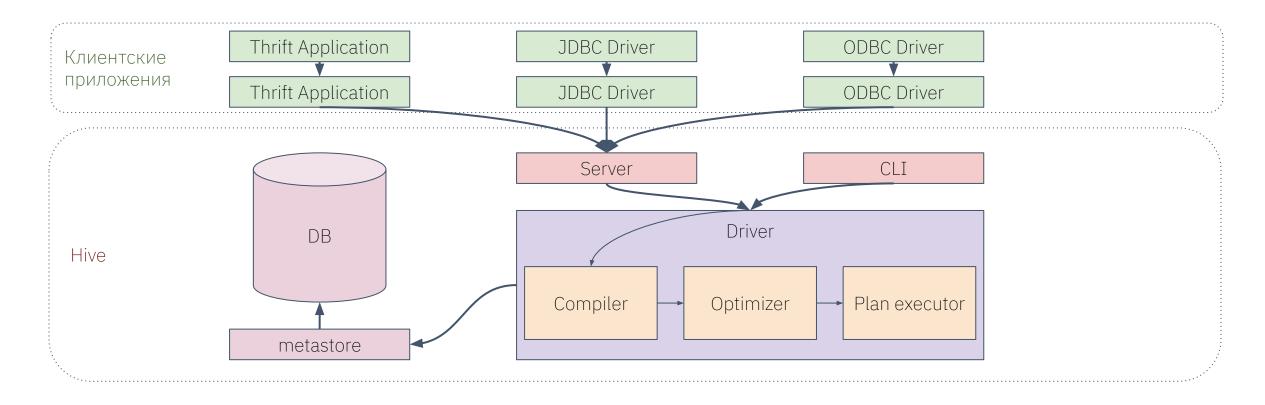
Оптимизатор составляет оптимальный план MapReduce и HDFS задач в виде графа





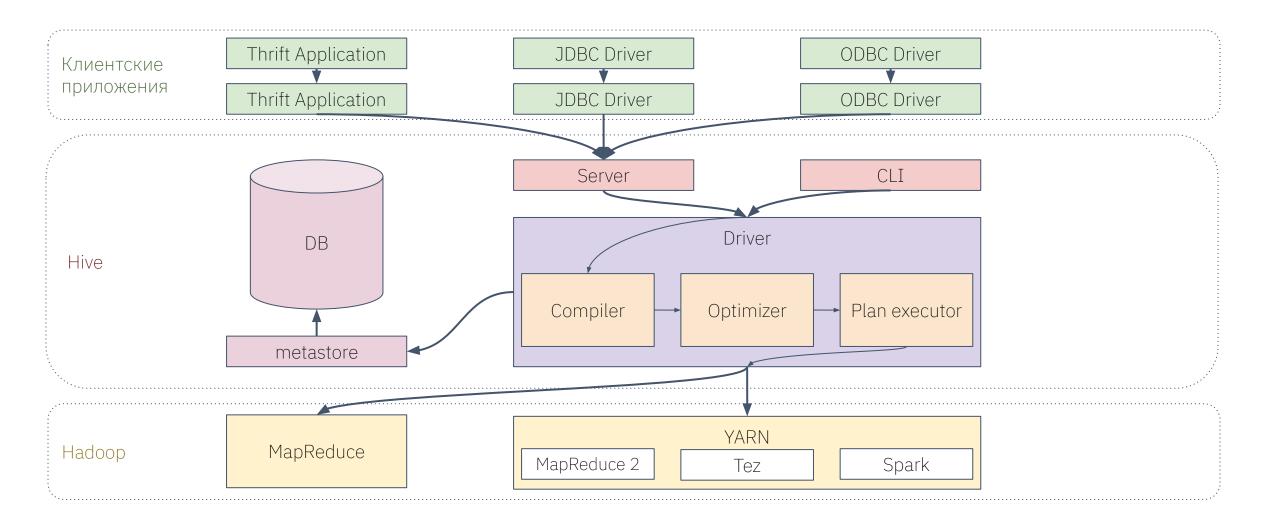
Исполнитель отвечает за запуск и исполнения графа задач





Метахранилище содержит все метаданные Hive





ДВИЖКИ HIVE



hive.execution.engine=mr

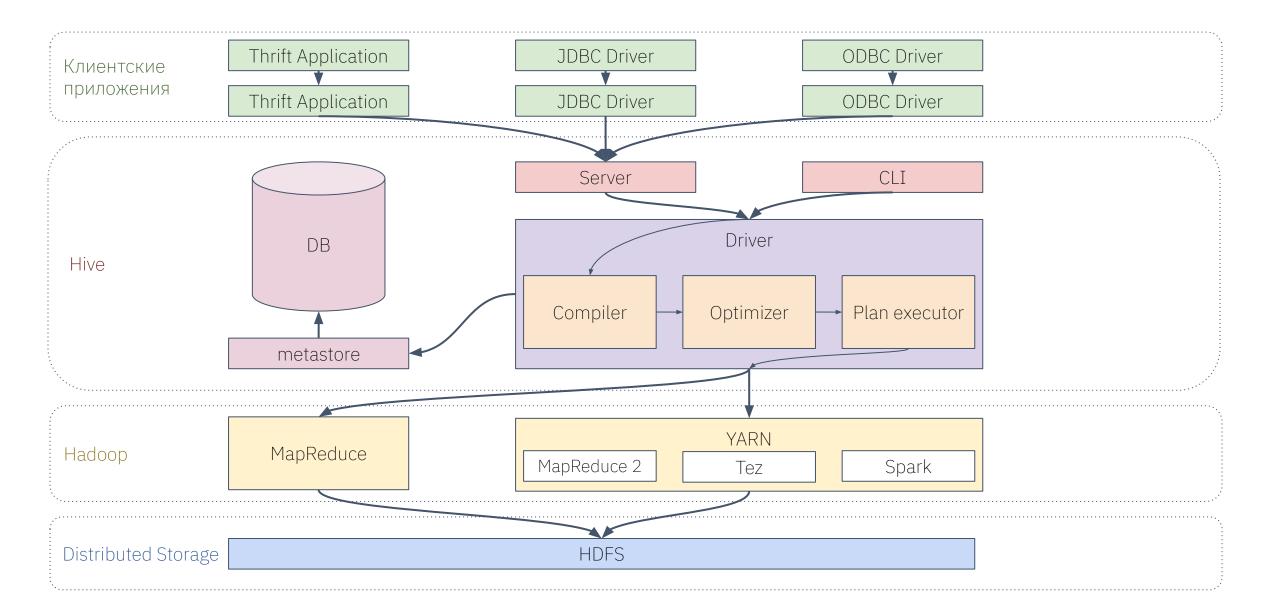


hive.execution.engine=spar
k



hive.execution.engine=tez







МЕТАХРАНИЛИЩЕ

Репозиторий метаданных Hive. Состоит из двух компонентов:

- daemon
- база данных

По умолчанию в качестве базы данных используется Apache Derby, работающий в одном JVM процессе с Hive. В этом случае может быть открыт только один сеанс работы.

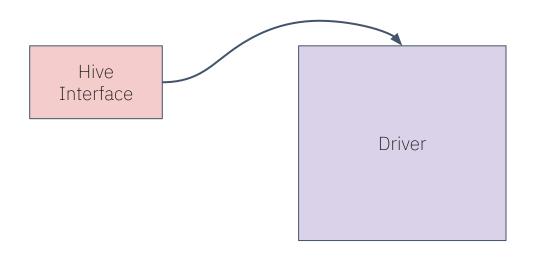
Для поддержки множества пользователей следует использовать любую JDBC-совместимую базу данных (MySQL, PostgreSQL...)



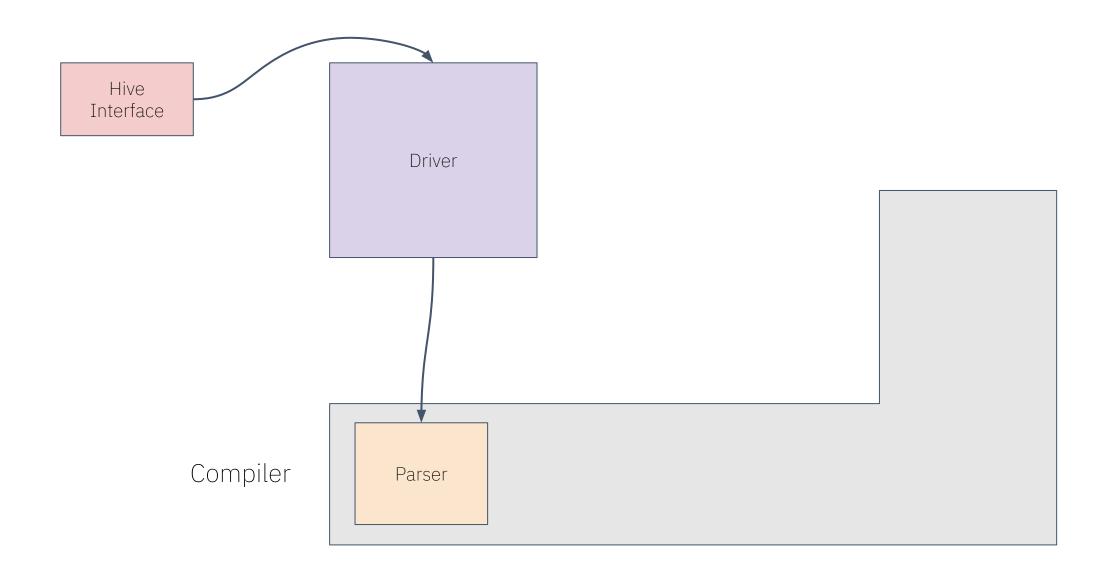


Hive Interface

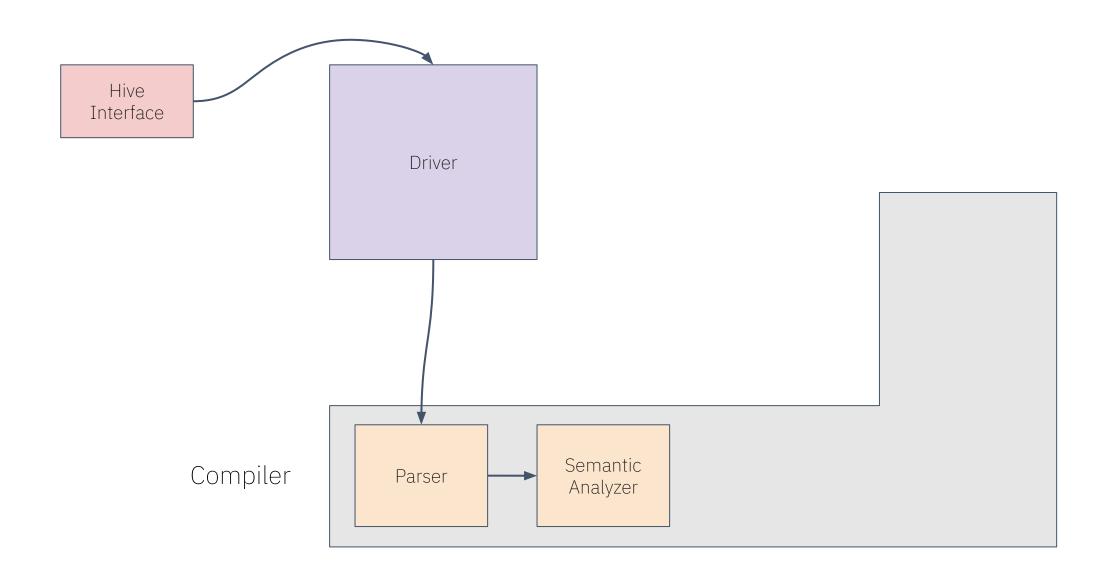




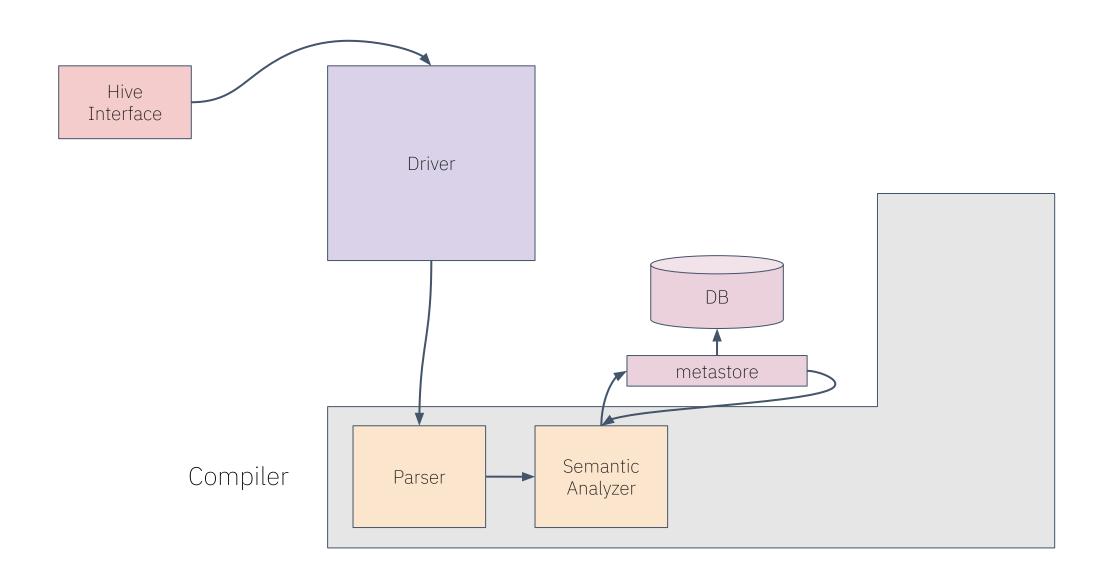




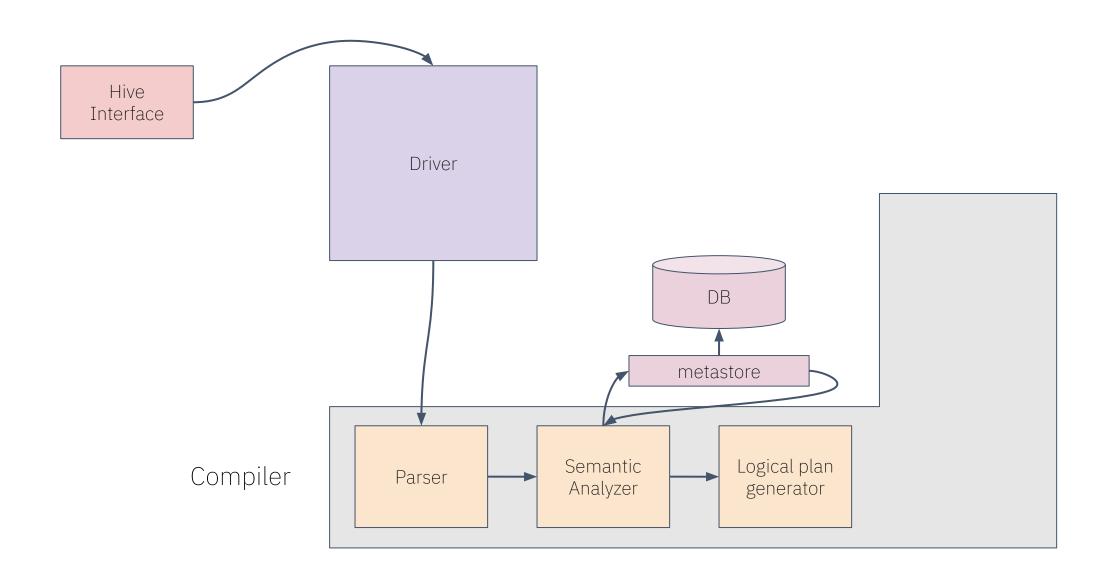




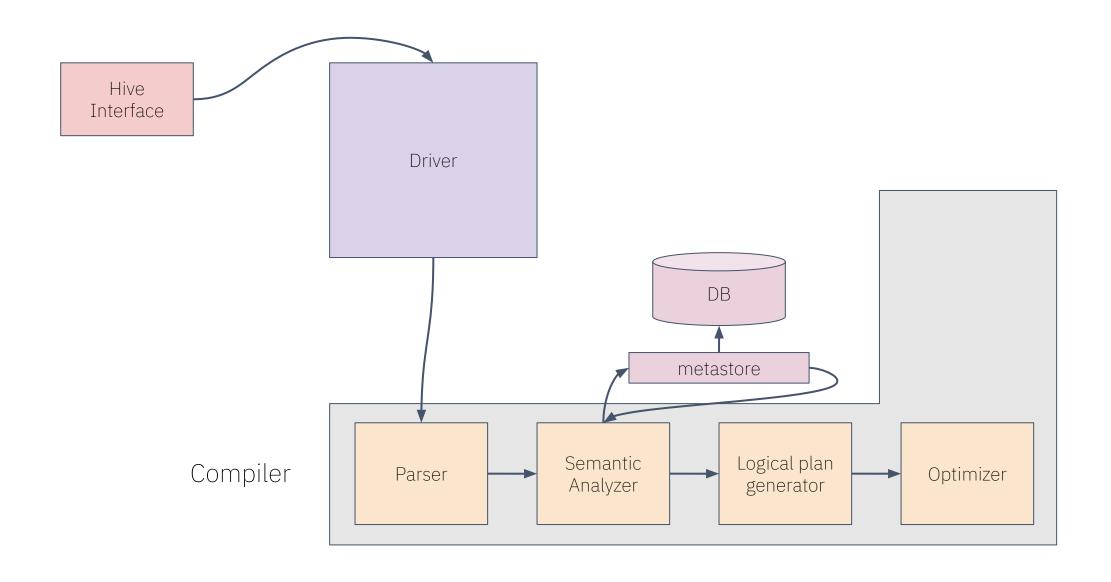




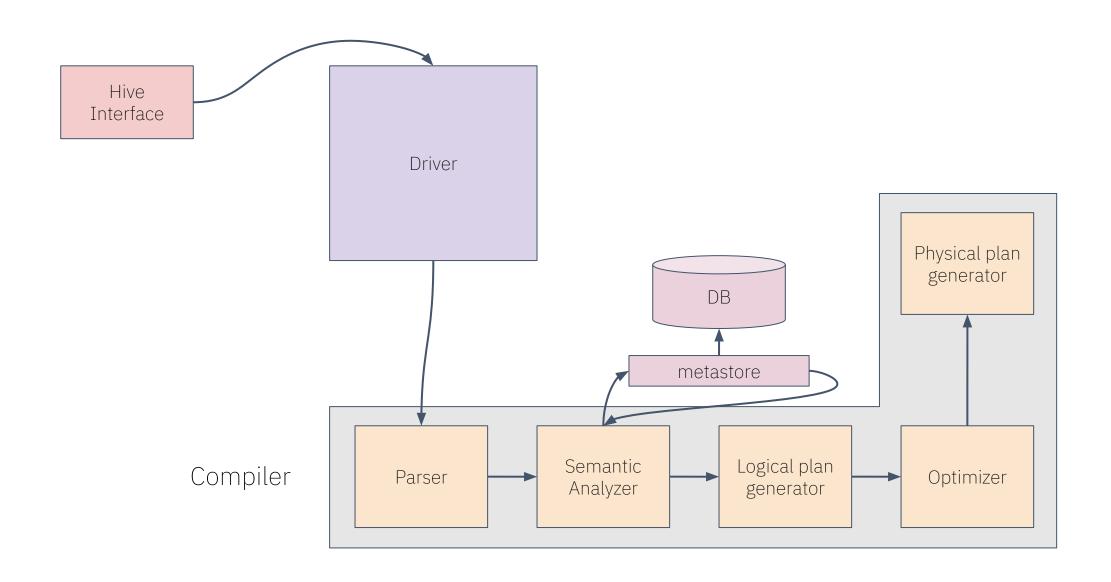




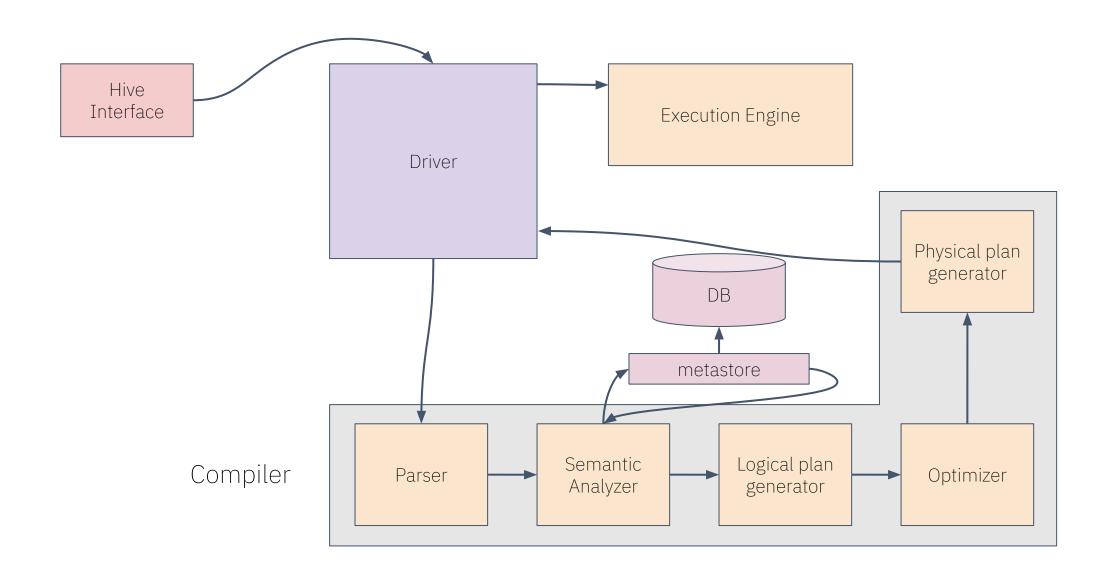




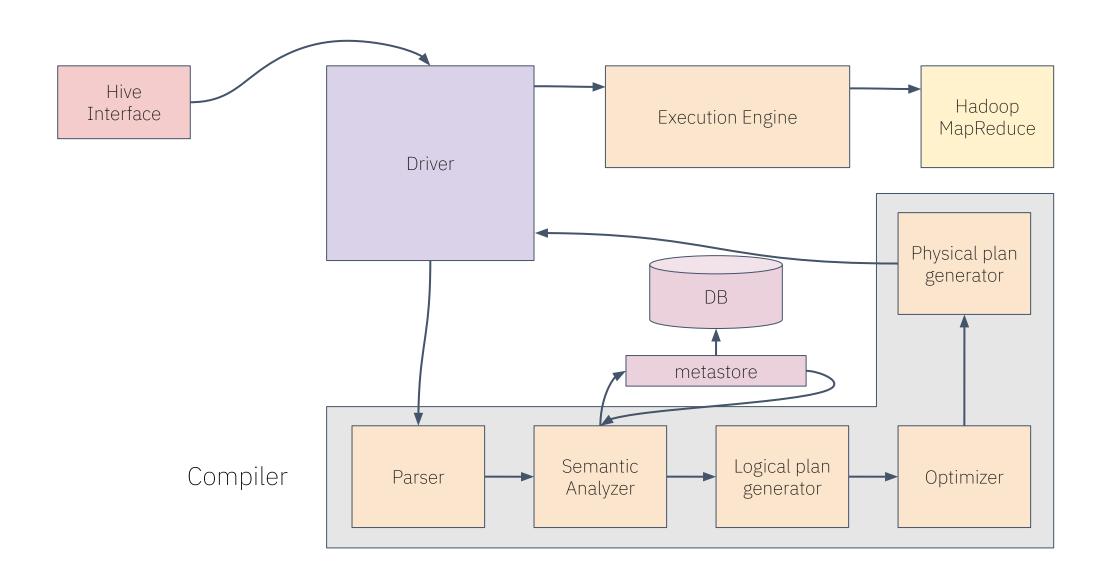




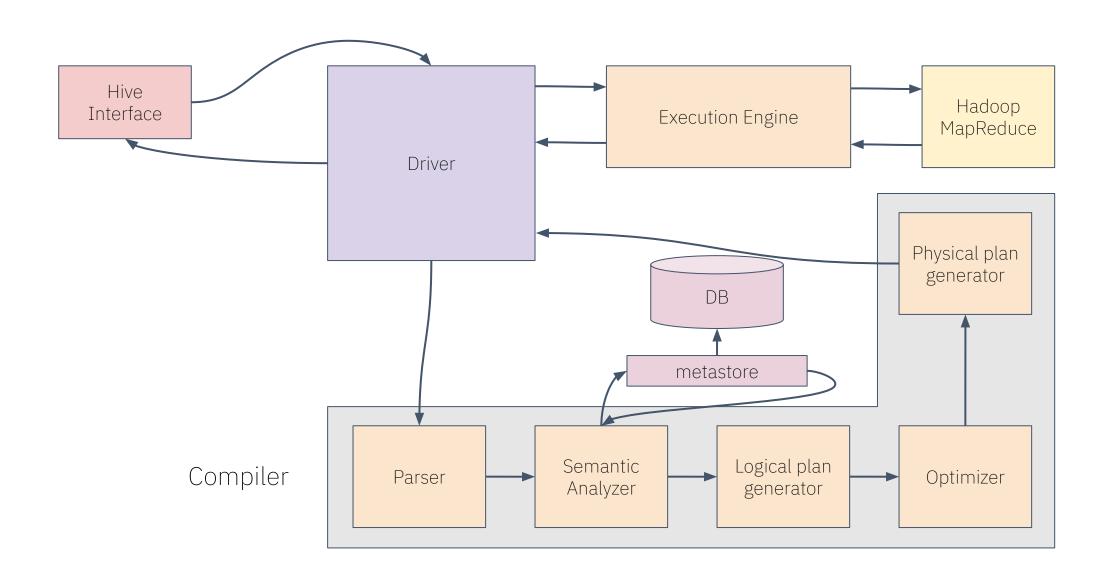










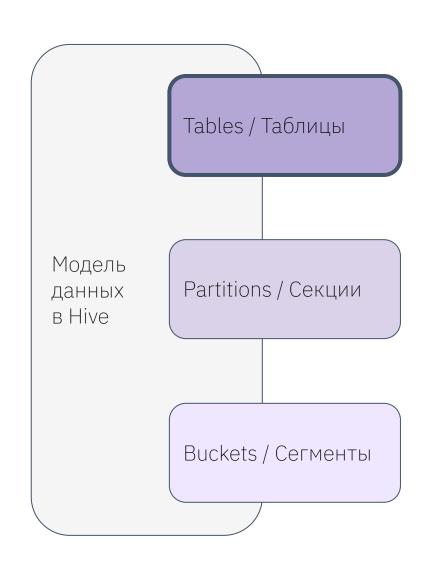












Таблицы создаются таким же образом, как в классических реляционных базах данных. Являются физическим представлением данных, хранящихся в директории внутри файловой системы:

/user/hive/warehouse/mytable

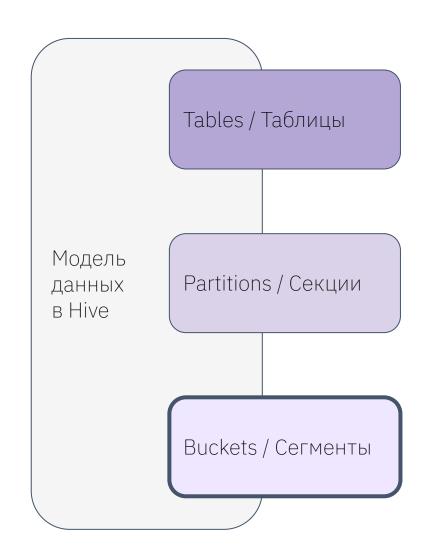




Данные в таблицах разбитые по ключу называются партициями. Ключом является значение одной из колонок:

/user/hive/warehouse/mytable/City=Moscow
/user/hive/warehouse/mytable/City=Tambov





Партиционированные данные могут быть также разбиты на бакеты. Оптимальным размером бакета является размер блока в HDFS:

/user/hive/warehouse/mytable/City=Moscow/part-00000
/user/hive/warehouse/mytable/City=Moscow/part-00001

• • •

/user/hive/warehouse/mytable/City=Tambov/part-00000
/user/hive/warehouse/mytable/City=Tambov/part-00002
/user/hive/warehouse/mytable/City=Tambov/part-00003

. . .



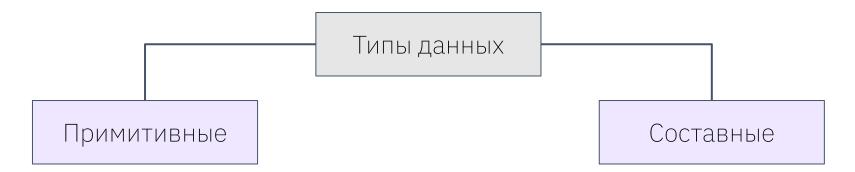
ПЕРЕРЫВ

10:00

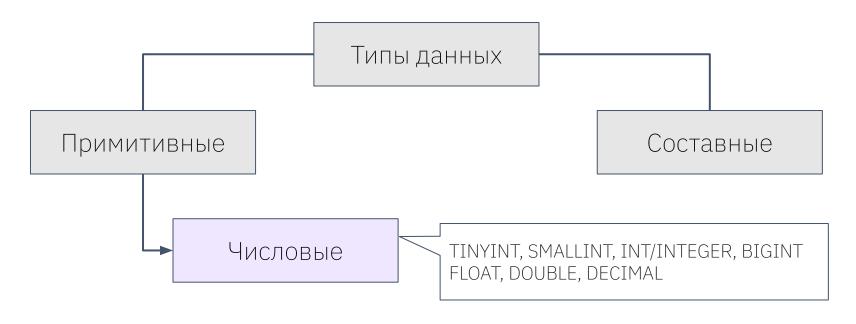


ТИПЫ ДАННЫХ

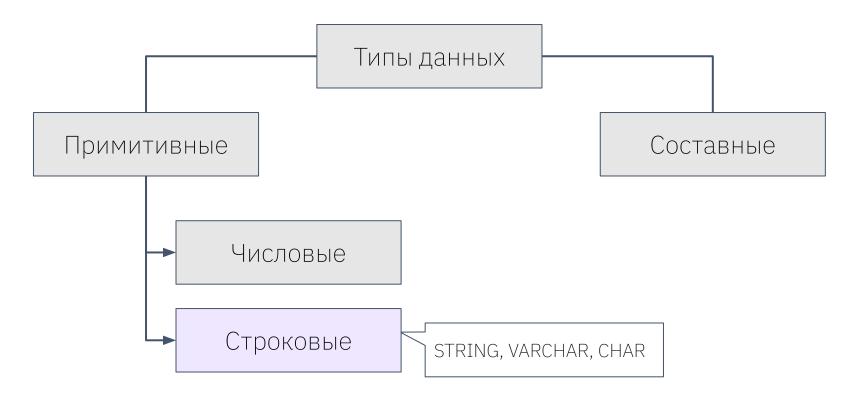




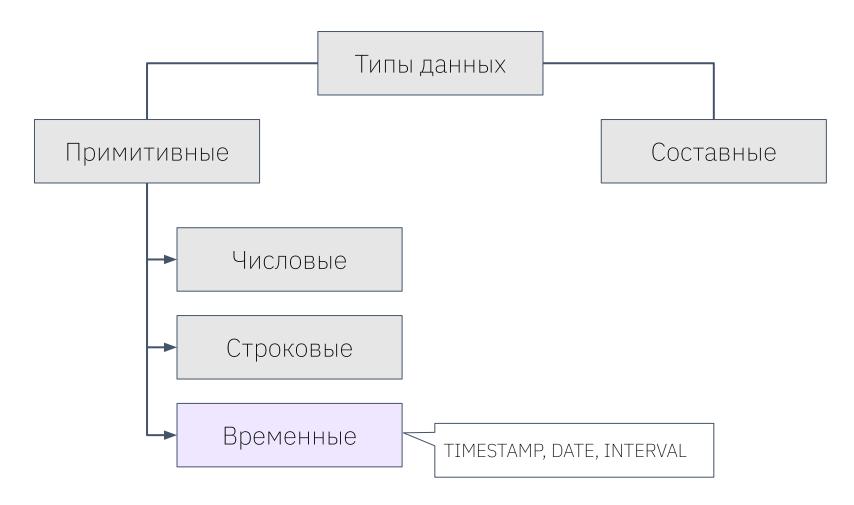








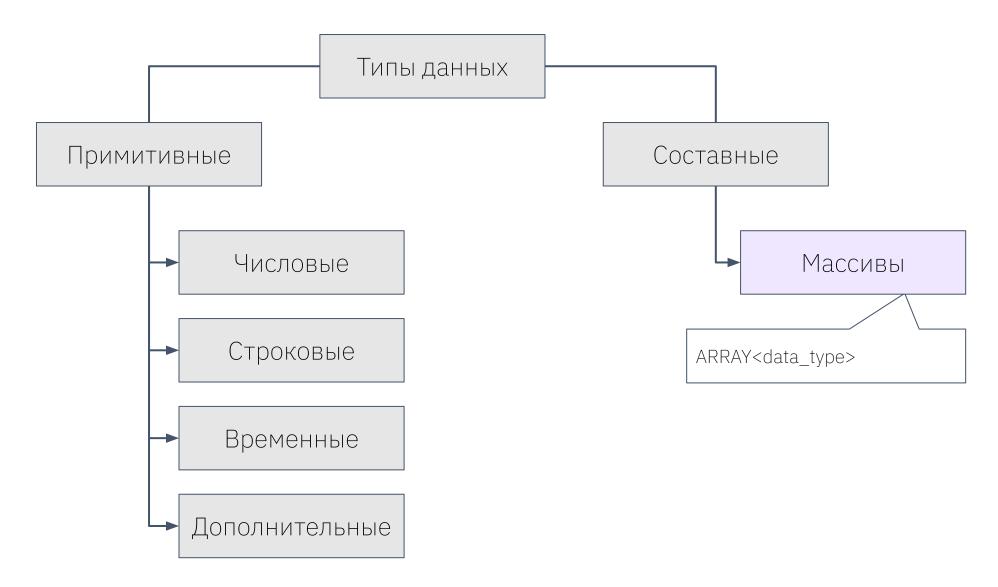






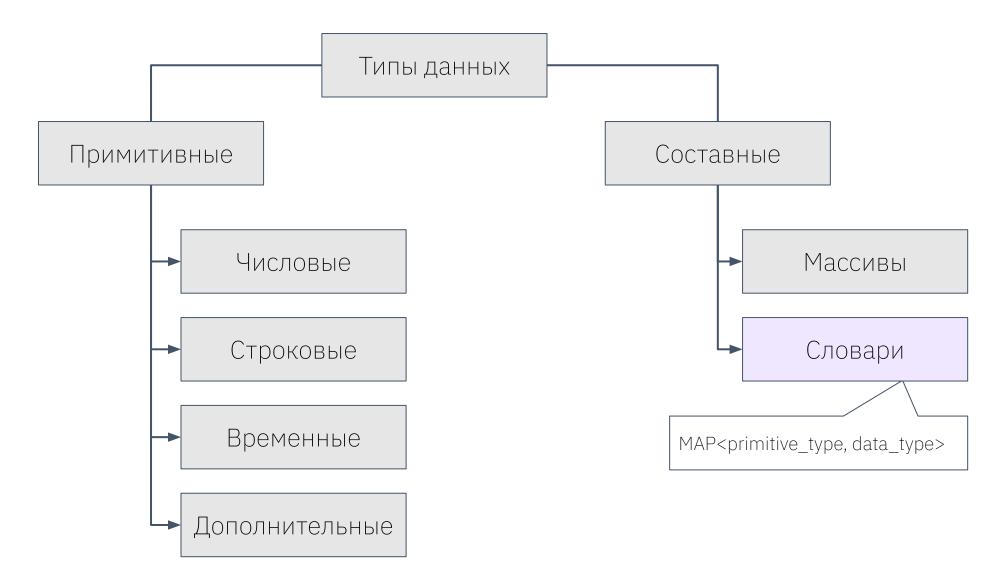




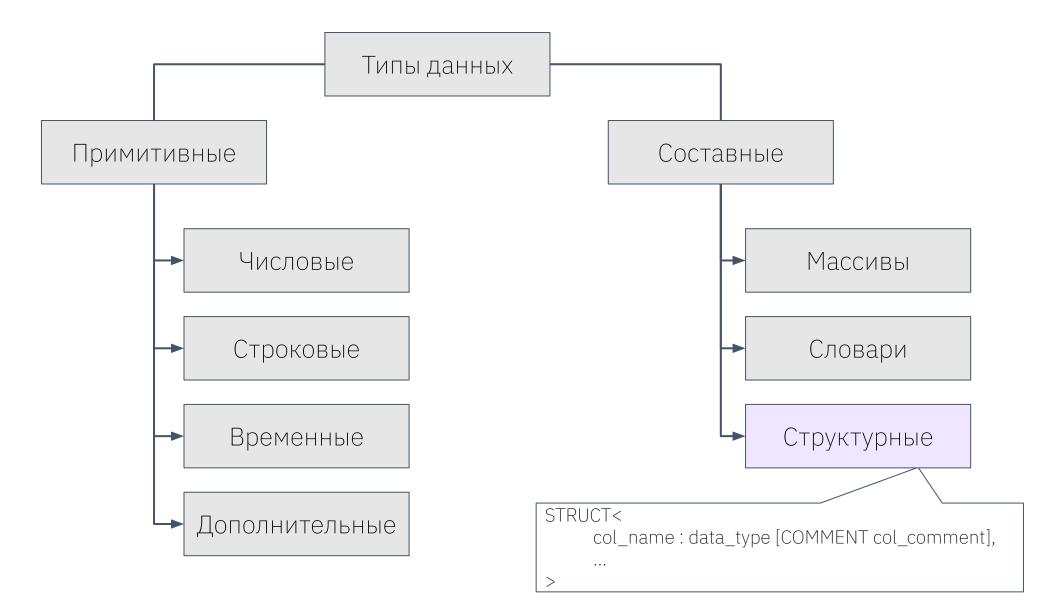




ТИПЫ ДАННЫХ

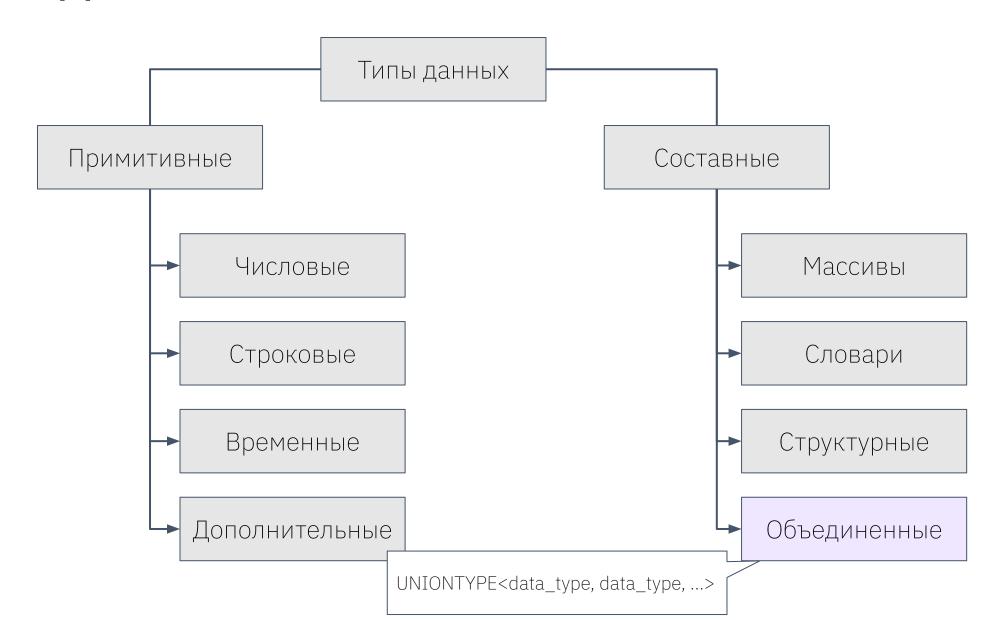








ТИПЫ ДАННЫХ





HQL



DDL

```
CREATE TABLE mytable(id INT, name STRING, age INT, # объявляем схему
city STRING)
COMMENT 'This is a sample table'
                                                        # комментарий для читаемости
PARTITIONED BY (city STRING)
                                                        # партиционирование
                                                        # строки разделяются '\n'
ROW FORMAT DELIMITED
                                                        # поля разделяются запятой
FIELDS TERMINATED BY ','
                                                        # хранится в виде текстового файла
STORED AS TEXTFILE;
```

Таблица создается в специальной директории warehouse и полностью находится под управлением Hive



DDL

```
CREATE EXTERNAL TABLE my_external_table(id INT, name STRING, age INT,
city STRING)
LOCATION '/user/ivanov/mytable';
```

Таблица не создается в warehouse. У Hive сохраняется только ссылка на неё



DDL

DROP TABLE mytable;

Так как таблица находится под управлением Hive, то произойдёт полное удаление данных вместе с метадатой

DROP TABLE my_external_table;

Так как внешняя таблица **не** находится под управлением Hive, то произойдёт удаление только метадаты внутри Hive. Данные останутся нетронутыми



DML

LOAD DATA LOCAL INPATH '/home/ivanov/peoples.txt'

INTO TABLE mytable;

Файл peoples.txt находится в локальной файловой системе и будет скопирован в директорию warehouse

LOAD DATA INPATH '/user/ivanov/peoples.txt'

INTO TABLE mytable;

Файл peoples.txt находится в HDFS и будет скопирован в директорию warehouse



DML

INSERT OVERWRITE TABLE newtable

SELECT * FROM mytable;

Все данные из таблицы *mytable* будут скопированы в **существующую** таблицу *newtable*

CREATE TABLE newtable

AS SELECT * FROM mytable;

Будет **создана** новая таблица *newtable* с такой же схемой и данными как в таблице *mytable*



ЗАПРОСЫ

SHOW TABLES;

Отобразить список всех таблиц в хранилище



ЗАПРОСЫ

```
SELECT * FROM mytable;
```

Показать все данные таблицы

```
SELECT COUNT(DISTINCT city) FROM mytable;
```

Агрегация

```
SELECT COUNT(*) FROM mytable GROUP BY city;
SELECT * FROM mytable SORT BY id DESC;
FROM mytable SELECT * ORDER BY id ASC;
```

Агрегация и сортировка



ЗАПРОСЫ

```
SELECT p.*, o.*
FROM mytable p

JOIN orders p
ON (p.id = o.id);
```

Поддерживается inner, left, right, full outer виды слияний Можно использовать множественное слияние



ФУНКЦИИ

Содержит большое количество встроенных функций: математические, статистические, строковые, даты/времени, условные, аггрегатные, преобразования типов, для работы с JSON, XML, составными типами данных. Полный список UDF функций можно посмотреть в официальной wiki или используя команды:

hive> **SHOW FUNCTIONS**;

hive> DESCRIBE FUNCTION lenght;

length (str | binary) - Returns the length of str or number of bytes in binary data



ФУНКЦИИ

Типы функций:

- UDF (User Defined Function) применяются построчно
- UDAF (User Defined Aggregate Function) используются совместно с GROUP BY оператором
- UDTF (User Defined Table Function) применяются на таблицу целиком

Стандартную библиотеку функций можно расширить своими, добавив в classpath Hive



HIVE VS RDBMS



Apache Hive

• Проверяет схему данных при **чтении**, что ускоряет *добавление* данных и позволяет работать с *неизвестной* схемой данных

RDBMS

• Проверяет схему при **записи**, что ускоряет *чтение* данных и повышает уровень их *консистентности*



Apache Hive

- Проверяет схему данных при **чтении**, что ускоряет *добавление* данных и позволяет работать с *неизвестной* схемой данных
- Размер данных измеряется петабайтами

- Проверяет схему при **записи**, что ускоряет *чтение* данных и повышает уровень их *консистентности*
- Размер данных измеряется терабайтами



Apache Hive

- Проверяет схему данных при **чтении**, что ускоряет *добавление* данных и позволяет работать с *неизвестной* схемой данных
- Размер данных измеряется петабайтами
- Ориентирован на модель "один раз записал, много раз прочитал"

- Проверяет схему при **записи**, что ускоряет *чтение* данных и повышает уровень их *консистентности*
- Размер данных измеряется терабайтами
- Поддерживается инструментарий как записи данных, так и чтения



Apache Hive

- Проверяет схему данных при **чтении**, что ускоряет *добавление* данных и позволяет работать с *неизвестной* схемой данных
- Размер данных измеряется петабайтами
- Ориентирован на модель "один раз записал, много раз прочитал"
- Несмотря на поддержку SQL является хранилищем данных

- Проверяет схему при **записи**, что ускоряет *чтение* данных и повышает уровень их *консистентности*
- Размер данных измеряется терабайтами
- Поддерживается инструментарий как записи данных, так и чтения
- Традиционная база данных, основанная на реляционной модели данных



Apache Hive

- Проверяет схему данных при **чтении**, что ускоряет *добавление* данных и позволяет работать с *неизвестной* схемой данных
- Размер данных измеряется петабайтами
- Ориентирован на модель "один раз записал, много раз прочитал"
- Несмотря на поддержку SQL является хранилищем данных
- Легко масштабируется при расширении кластера

- Проверяет схему при **записи**, что ускоряет *чтение* данных и повышает уровень их *консистентности*
- Размер данных измеряется терабайтами
- Поддерживается инструментарий как записи данных, так и чтения
- Традиционная база данных, основанная на реляционной модели данных
- Для масштабирования требуются соответствующие навыки





Использование HiveQL позволяет специалистам, знающим SQL, сразу начать работу с данными на кластере



Использование HiveQL позволяет специалистам, знающим SQL, сразу начать работу с данными на кластере

Наличие таких абстракций, как "таблицы", приближает пользовательский опыт к опыту работы с традиционными реляционными базами данных



Использование HiveQL позволяет специалистам, знающим SQL, сразу начать работу с данными на кластере

Наличие таких абстракций, как "таблицы", приближает пользовательский опыт к опыту работы с традиционными реляционными базами данных

RPC, JDBC, ODBC интерфейсы позволяют разрабатывать приложения удобным для пользователей способом



Использование HiveQL позволяет специалистам, знающим SQL, сразу начать работу с данными на кластере

Наличие таких абстракций, как "таблицы", приближает пользовательский опыт к опыту работы с традиционными реляционными базами данных

RPC, JDBC, ODBC интерфейсы позволяют разрабатывать приложения удобным для пользователей способом

Статическая типизация и богатый набор встроенных функций упрощает работу с данными и уменьшает вероятность появления ошибок



ПРАКТИКА



ПОДНИМАЕМ ЛОКАЛЬНЫЙ КЛАСТЕР

docker start -i gbhdp



ПОДГОТОВКА К УСТАНОВКЕ

Предварительно создаем служебные директории в HDFS:

- \$ hdfs dfs -mkdir -p /user/hive/warehouse
- \$ hdfs dfs -chmod a+w /user/hive/warehouse



УСТАНОВКА

Скачиваем и распаковываем дистрибутив:

```
$ wget https://apache-mirror.rbc.ru/pub/apache/hive/hive-2.3.9/apache-hive-2.3.9-bin.tar.gz
    $ tar xzf apache-hive-2.3.9-bin.tar.gz
    $ rm apache-hive-2.3.9-bin.tar.gz
    $ mv apache-hive-2.3.9-bin hive
Задаем необходимые переменные окружения:
    $ cd hive
    $ export HIVE_HOME=`pwd`
    $ export PATH=$PATH:$HIVE_HOME/bin
Инициализируем метастор:
    $ schematool -dbType derby -initSchema
Проверяем работу:
    $ hive -e 'show tables;'
    OK
    Time taken: 6.128 seconds
```



HACTPOЙKA HIVE SERVER



ЗАПУСК HIVE SERVER

```
Запускаем в фоне Hive Server:
    $ hiveserver2 &> /dev/null &
Подключаемся через beeline cli:
    $ beeline -u jdbc:hive2://localhost:10000
Проверяем работу:
    0: jdbc:hive2://localhost:10000> show tables;
   OK
    +----+
     tab_name
    No rows selected (0.404 seconds)
Выходим:
    0: jdbc:hive2://localhost:10000> !q
    Closing: 0: jdbc:hive2://localhost:10000
```



ИНТЕРАКТИВНАЯ ОБОЛОЧКА

Работа в Hive Shell сводится к исполнению команд на HiveQL

При передаче ключа - f можно исполнить заранее написанный скрипт:

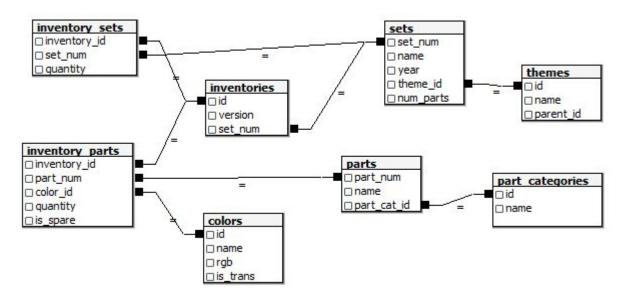
hive -f script.q

Либо через ключ -е выполнить произвольный запрос:

hive -e 'SELECT * FROM mytable'



Поработаем с датасетом <u>LEGO Database</u>:



Загрузим данные themes и sets в Hive таблицы и найдем набор с самым большим количеством деталей



Загружаем данные в контейнер:

- \$ docker cp sets.csv gbhdp:/home/hduser/
- \$ docker cp themes.csv gbhdp:/home/hduser/

Переключаемся на терминал с хадуп сессией и включаем интерактивную оболочку:

\$ hive



Создаем таблицу для themes.csv:

```
CREATE TABLE lego_themes(id INT, name STRING, parent_id INT)

COMMENT 'Information on lego themes'

ROW FORMAT DELIMITED

FIELDS TERMINATED BY ','

STORED AS TEXTFILE

TBLPROPERTIES('skip.header.line.count'='1');
```



Создаем таблицу для sets.csv:

```
CREATE TABLE lego_sets(set_num STRING, name STRING, year INT, theme_id INT,
num_parts INT)
   COMMENT 'Information on lego sets'
   ROW FORMAT DELIMITED
   FIELDS TERMINATED BY ','
   STORED AS TEXTFILE
   TBLPROPERTIES('skip.header.line.count'='1');
```



```
hive> CREATE TABLE lego_themes(id INT, name STRING, parent_id INT)
    > COMMENT 'Information on lego themes'
    > ROW FORMAT DELIMITED
    > FIELDS TERMINATED BY ','
    > STORED AS TEXTFILE;
OK
Time taken: 0.18 seconds
hive> CREATE TABLE lego_sets(set_num STRING, name STRING, year INT, theme_id INT, num_parts INT)
    > COMMENT 'Information on lego sets'
    > ROW FORMAT DELIMITED
    > FIELDS TERMINATED BY ','
    > STORED AS TEXTFILE;
0K
Time taken: 0.086 seconds
hive> SHOW TABLES;
OK
lego_sets
lego_themes
Time taken: 0.028 seconds, Fetched: 2 row(s)
```



Загружаем данные в таблицы:

```
LOAD DATA LOCAL INPATH '/home/hduser/themes.csv' INTO TABLE lego_themes;
LOAD DATA LOCAL INPATH '/home/hduser/sets.csv' INTO TABLE lego_sets;
```

```
hive> LOAD DATA LOCAL INPATH '/home/hduser/themes.csv' INTO TABLE lego_themes; Loading data to table default.lego_themes

OK
Time taken: 6.916 seconds
hive> LOAD DATA LOCAL INPATH '/home/hduser/sets.csv' INTO TABLE lego_sets;
Loading data to table default.lego_sets

OK
Time taken: 0.326 seconds
```



```
hive> SELECT * FROM lego_themes LIMIT 5;
0K
NULL
              NULL
       name
      Technic NULL
1
       Arctic Technic 1
3
       Competition
       Expert Builder 1
Time taken: 0.131 seconds, Fetched: 5 row(s)
hive> SELECT * FROM lego_sets LIMIT 5;
OK
              NULL NULL
                             NULL
set_num name
       Weetabix Castle 1970 414
00-1
                                    471
0011-2 Town Mini-Figures 1978
                                    84
                                           12
0011-3 Castle 2 for 1 Bonus Offer
                                    1987
                                           199
0012-1 Space Mini-Figures
                                           12
                             1979
                                    143
Time taken: 0.137 seconds, Fetched: 5 row(s)
```



Набор с самым большим количеством деталей:

SELECT name, year, num_parts

FROM lego_sets

WHERE num_parts IN (SELECT Max(num_parts) FROM lego_sets);



```
hive> SELECT name, year, num_parts FROM lego_sets WHERE num_parts IN (SELECT Max(num_parts) FROM lego_sets);
WARNING: Hive-on-MR is deprecated in Hive 2 and may not be available in the future versions. Consider using
leases.
Query ID = hduser_20210507211902_be32c787-3eec-4d71-8299-2882b66eea68
Total jobs = 3
Launching Job 1 out of 3
Number of reduce tasks determined at compile time: 1
In order to change the average load for a reducer (in bytes):
  set hive.exec.reducers.bytes.per.reducer=<number>
In order to limit the maximum number of reducers:
  set hive.exec.reducers.max=<number>
In order to set a constant number of reducers:
  set mapreduce.job.reduces=<number>
Job running in-process (local Hadoop)
2021-05-07 21:19:03,772 Stage-2 map = 100%, reduce = 100%
Ended Job = job_local2082942877_0002
Stage-5 is selected by condition resolver.
Stage-1 is filtered out by condition resolver.
SLF4J: Class path contains multiple SLF4J bindings.
SLF4J: Found binding in [jar:file:/home/hduser/hive/lib/log4j-slf4j-impl-2.6.2.jar!/org/slf4j/impl/StaticLogo
SLF4J: Found binding in [jar:file:/home/hduser/hadoop/share/hadoop/common/lib/slf4j-log4j12-1.7.25.jar!/org/s
SLF4J: See http://www.slf4j.org/codes.html#multiple_bindings for an explanation.
SLF4J: Actual binding is of type [org.apache.logging.slf4j.Log4jLoggerFactory]
                                                                               maximum memory = 477626368
2021-05-07 21:19:14
                        Starting to launch local task to process map join;
2021-05-07 21:19:14
                        Dump the side-table for tag: 1 with group count: 1 into file: file:/tmp/hduser/b7eb2b
9210616200196-1/-local-10005/HashTable-Stage-3/MapJoin-mapfile01--.hashtable
2021-05-07 21:19:14
                        Uploaded 1 File to: file:/tmp/hduser/b7eb2b89-3d02-45b1-8725-dfc0f2d3c944/hive_2021-0
ge-3/MapJoin-mapfile01--.hashtable (280 bytes)
2021-05-07 21:19:14
                     End of local task; Time Taken: 0.463 sec.
Execution completed successfully
MapredLocal task succeeded
Launching Job 3 out of 3
Number of reduce tasks is set to 0 since there's no reduce operator
Job running in-process (local Hadoop)
2021-05-07 21:19:17,029 Stage-3 map = 100%, reduce = 0%
Ended Job = job_local232705884_0003
MapReduce Jobs Launched:
Stage-Stage-2: HDFS Read: 5132484 HDFS Write: 2075420 SUCCESS
Stage-Stage-3: HDFS Read: 3073756 HDFS Write: 1037710 SUCCESS
Total MapReduce CPU Time Spent: 0 msec
Taj Mahal
                2008 5922
Time taken: 14.916 seconds, Fetched: 1 row(s)
```



Добавим к выдаче тему набора:

```
SELECT s.name, s.year, t.name AS theme, s.num_parts
FROM lego_sets s

JOIN lego_themes t ON (s.theme_id = t.id)
WHERE s.num_parts IN (SELECT Max(num_parts) FROM lego_sets);
```

```
OK
Taj Mahal 2008 Sculptures 5922
Time taken: 24.762 seconds, Fetched: 1 row(s)
```



ОСТАНОВКА ЛОКАЛЬНОГО КЛАСТЕРА

exit



HIVE VS PIG VS IMPALA

Pig



Hive



Impala





Pig vs Hive & Impala

```
input_lines = LOAD '/tmp/word.txt' AS (line:chararray);
words = FOREACH input_lines GENERATE FLATTEN(TOKENIZE(line)) AS word;
filtered_words = FILTER words BY word MATCHES '\\w+';
word_groups = GROUP filtered_words BY word;
word_count = FOREACH word_groups GENERATE COUNT(filtered_words) AS count, group AS word;
ordered_word_count = ORDER word_count BY count DESC;
STORE ordered_word_count INTO '/tmp/results.txt';
```

```
DROP TABLE IF EXISTS docs;

CREATE TABLE docs (line STRING);

LOAD DATA INPATH 'input_file' OVERWRITE INTO TABLE docs;

CREATE TABLE word_counts AS

SELECT word, count(1) AS count FROM

(SELECT explode(split(line, '\s')) AS word FROM docs) temp

GROUP BY word

ORDER BY word;
```

Impala daemon (impalad)

- Запущен на каждом узле кластера.
- Читает и пишет файлы данных
- Принимает запросы на выполнение от impala-shell, Hue, JDBC, или ODBC.
- Параллелизирует работу запроса и передает результаты центральному координатору.

র্জ GeekBrains

Impala

Impala Statestore (statestored)

- Мониторит состояние узлов кластера. Обычно один на кластер.
- Рассылает информацию о доступности узлов по кластеру.

Impala Catalog Service (catalogd)

- Следит за метаданными о объектах в кластере.
- Обновляет и рассылает обновления метаданных.



ПРАКТИЧЕСКОЕ ЗАДАНИЕ



ПРАКТИЧЕСКОЕ ЗАДАНИЕ

Приложите составленные запросы и первые 10 строк результатов:

- 1. Установите Apache Hive в ваш контейнер с Apache Hadoop
- 2. Скачайте датасет <u>lego-database</u> и импортируйте его в Hive
- 3. Составьте запрос, который выведет имя набора (sets.name) с самым большим количеством деталей (sets.num_parts)
- 4. Составьте запрос, который выведет в каком году (sets.year) вышло больше всего наборов
- 5. Составьте запрос, который выведет общее количество деталей (inventory_parts.quantity) для каждого из цветов (colors.name)
- 6. * Измените Dockerfile так, чтобы вместе с Hadoop устанавливался и запускался Hive

Спасибо! Каждый день вы становитесь лучше:)

