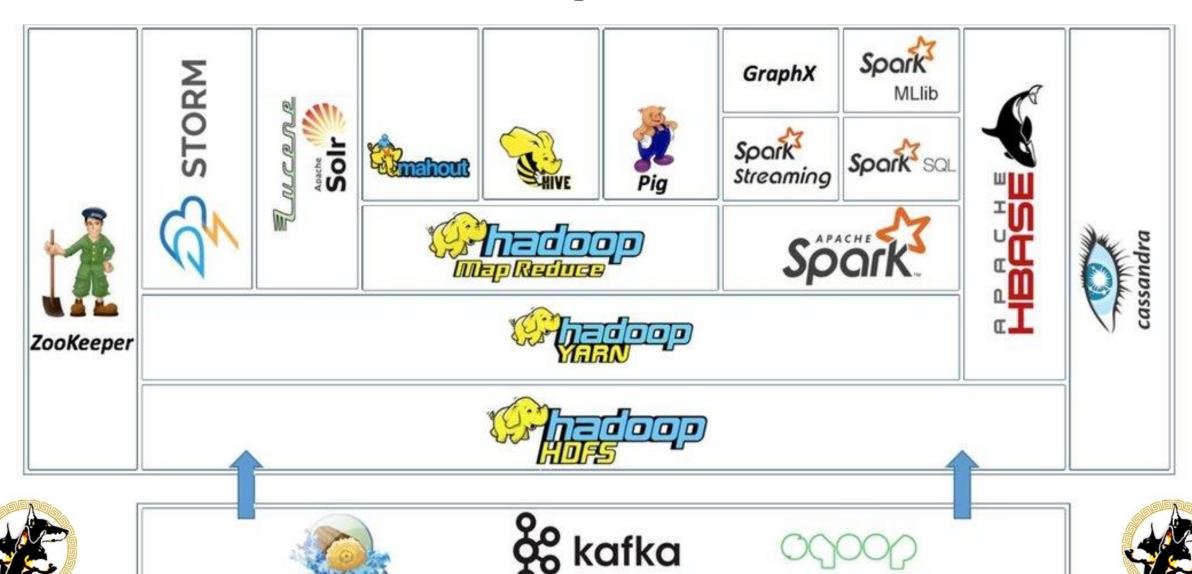


Загрузка данных

ETL vs ELT, Batch vs Streaming, Sqoop, Flume

Экосистема Hadoop





ВИДЫ ПОЛУЧЕНИЯ ДАННЫХ

ETL

- 1.Extract
- 2.Transform
- 3.Load



ETL

- 1.Extract
- 2.Transform
- 3.Load

ELT

- 1.Extract
- 2.Load
- 3.Transform



ETL

- 1.Extract
- 2.Transform
- 3.Load

ELT

- 1.Extract
- 2.Load
- 3.Transform

Batch

- T-1
- Micro-batch



ETL

- 1.Extract
- 2.Transform
- 3.Load

ELT

- 1.Extract
- 2.Load
- 3.Transform

Batch

- T-1
- Micro-batch

Streaming

- NRT (near real time)
- Real time





ИНСТРУМЕНТЫ РАБОТЫ С ДАННЫМИ

Инструменты

- HDFS (hdfs dfs -get, distcp)
- 2. Apache SQOOP
- 3. ODBC/JDBC Connectors
- 4. Informatica
- 5. Oracle Data Integrator

- 6. Apache NiFi
- 7. Apache Flume
- 8. Apache Spark
- 9. Apache Flink
- 10. Apache Kafka
- 11. Apache Storm
- 12. Apache Samza
- 13. ...

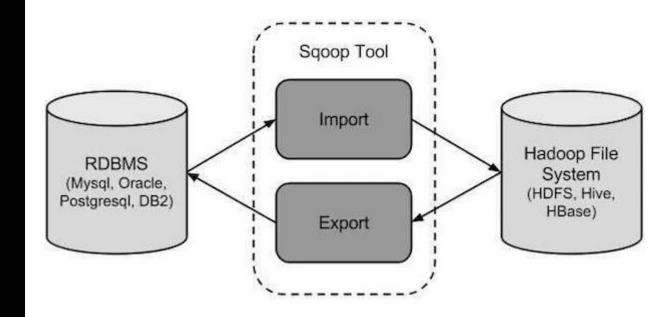


SQOOP

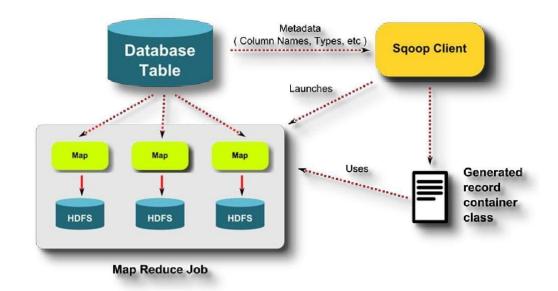








SQOOP Architecture



ODBC/JDBC Connectors

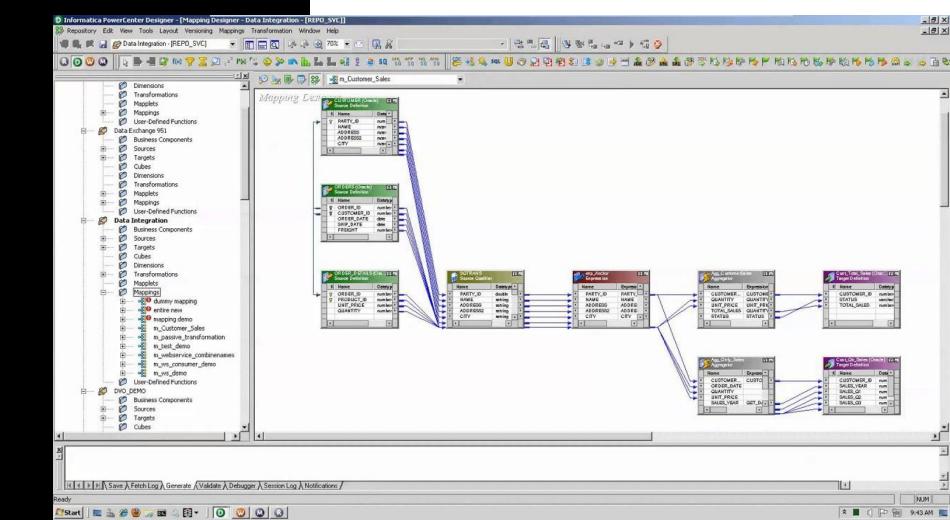
- - క్కి GeekBrains

- 1. Медленно
- 2. Универсально

- **Informatica**

⟨⟨⟩⟩ GeekBrains

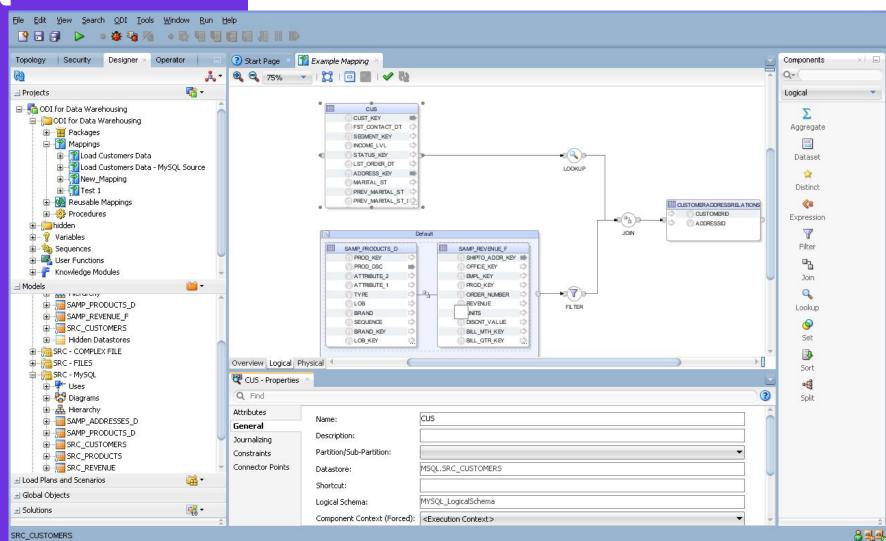
- Якобы ускоряет разработку
- 2. Якобы легче, чем код





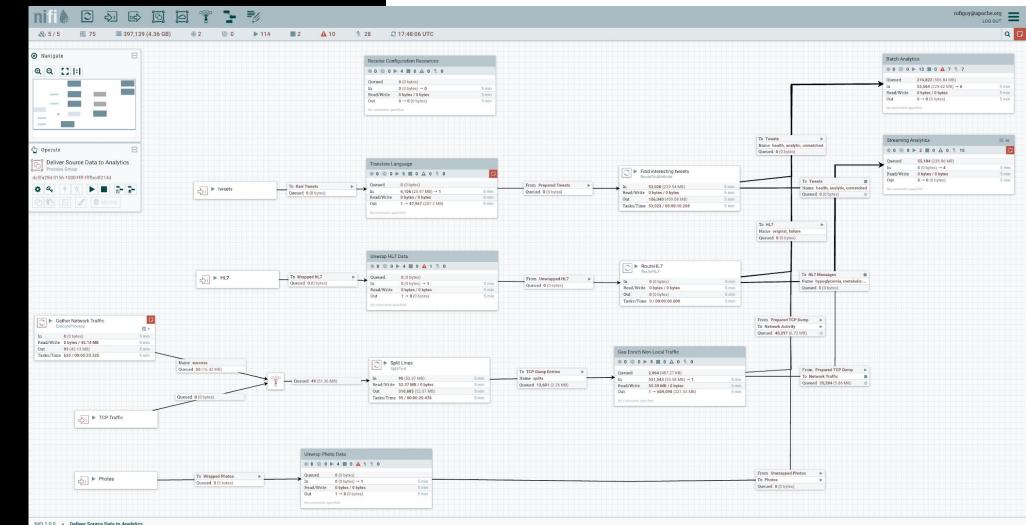
Oracle Data Integrator







Apache NiFi



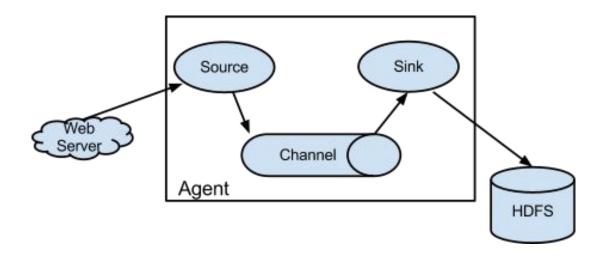


⟨⟨⟩⟩ GeekBrains

Apache Flume









Apache Spark

Apache Flink





Умеет все, но с небольшой задержкой



Тот же Spark, только быстрее. Минусы умалчиваются

Apache Kafka







Не только транспорт, но еще и процессинг



ПЕРЕРЫВ

10:00



ПРАКТИКА



ПОДНИМАЕМ ЛОКАЛЬНЫЙ КЛАСТЕР

docker start -i gbhdp



APACHE SQOOP



YCTAHOBKA SQOOP

Скачиваем и распаковываем дистрибутив:

Compiled by maugli on Thu Dec 21 15:59:58 STD 2017

```
$ wget <a href="http://archive.apache.org/dist/sqoop/1.4.7/sqoop-1.4.7.bin">http://archive.apache.org/dist/sqoop/1.4.7/sqoop-1.4.7.bin</a> hadoop-2.6.0.tar.gz
    $ tar xzf sqoop-1.4.7.bin_hadoop-2.6.0.tar.gz
    $ rm sqoop-1.4.7.bin_hadoop-2.6.0.tar.gz
    $ mv sqoop-1.4.7.bin_hadoop-2.6.0 sqoop
Задаем необходимые переменные окружения:
    $ cd sqoop
    $ export SQOOP_HOME=`pwd`
    $ export PATH=$PATH:$SQOOP_HOME/bin
    $ export HADOOP_MAPRED_HOME=$HADOOP_HOME
    $ export HADOOP_COMMON_HOME=$HADOOP_HOME
Проверяем работу:
    $ sqoop-version
    Sqoop 1.4.7
    git commit id 2328971411f57f0cb683dfb79d19d4d19d185dd8
```



ПРИМЕРЫ SQOOP

```
Копируем зависимости из Hive:
```

```
$ cp $HIVE_HOME/jdbc/hive-jdbc-2.3.9-standalone.jar $SQ00P_HOME/lib/
```

Смотрим таблицы в Hive:

```
$ sqoop list-tables \
    --connect jdbc:hive2://localhost:10000 \
    --driver org.apache.hive.jdbc.HiveDriver
```



ПРИМЕРЫ SQOOP

Экспортируем данные из MySQL в HDFS:



ПРИМЕРЫ SQOOP

Экспортируем данные из MySQL в Hive:



APACHE FLUME



YCTAHOBKA FLUME

Скачиваем и распаковываем дистрибутив:

```
$ wget https://mirror.softaculous.com/apache/flume/1.9.0/apache-flume-1.9.0-bin.tar.gz
    $ tar xzf apache-flume-1.9.0-bin.tar.gz
    $ rm apache-flume-1.9.0-bin.tar.gz
    $ mv apache-flume-1.9.0-bin flume
Задаем необходимые переменные окружения:
    $ cd flume
    $ export FLUME_HOME=`pwd`
    $ export PATH=$PATH:$FLUME_HOME/bin
Проверяем работу:
    $ flume-ng version
    Flume 1.9.0
    Source code repository: https://git-wip-us.apache.org/repos/asf/flume.git
    Revision: d4fcab4f501d41597bc616921329a4339f73585e
    Compiled by fszabo on Mon Dec 17 20:45:25 CET 2018
    From source with checksum 35db629a3bda49d23e9b3690c80737f9
```



ЗАПУСК FLUME

Создадим файл heartbeat.sh:

```
START_DATE=`date`
    COUNT=0
    while [ true ]
    do
        NOW_DATE=`date`
        echo I live for $(( (`date -d "$START_DATE" +%s` - `date -d "$NOW_DATE" +%s`) / (1000) ))
seconds\;`(date -d "$START_DATE" +%Y-%m-%d:%H.%M.%S)`\;`(date -d "$START_DATE" +%Y-%m-%d:%H.%M.%S)`\;I
did it $(( $COUNT + 1 )) times
        COUNT=$(( $COUNT + 1 ))
        sleep 10
        done
```



ЗАПУСК FLUME

Создадим конфигурацию heartbeat.conf:

```
# Naming the components on the current agent
HeartbeatFlume.sources = Exec
HeartbeatFlume.channels = MemChannel
HeartbeatFlume.sinks = MySink
# Describing/Configuring the source
HeartbeatFlume.sources.Exec.type = exec
HeartbeatFlume.sources.Exec.command = /home/hduser/heartbeat.sh
# Describing/Configuring the console sink
HeartbeatFlume.sinks.MySink.type = hdfs
HeartbeatFlume.sinks.MySink.hdfs.path = /tmp/heartbeat
HeartbeatFlume.sinks.MySink.hdfs.fileSuffix = .log
# Describing/Configuring the channel
HeartbeatFlume.channels.MemChannel.type = memory
HeartbeatFlume.channels.MemChannel.capacity = 10000000
HeartbeatFlume.channels.MemChannel.transactionCapacity = 100
# Bind the source and sink to the channel
HeartbeatFlume.sources.Exec.channels = MemChannel
HeartbeatFlume.sinks.MySink.channel = MemChannel
```



ЗАПУСК FLUME

Запустим приложение:

```
$ flume-ng agent \
    --conf-file /home/hduser/heartbeat.conf \
    --name HeartbeatFlume \
    -Dflume.root.logger=INFO,console &> /dev/null &
```



ИМПОРТ ДАННЫХ FLUME

Создаем таблицу данных Flume с указанием внешней директории:

CREATE TABLE heartbeat(c1 STRING, c2 STRING, c3 STRING, c4 STRING)

ROW FORMAT DELIMITED

FIELDS TERMINATED BY ';'

STORED AS INPUTFORMAT 'org.apache.hadoop.mapred.SequenceFileInputFormat'

OUTPUTFORMAT 'org.apache.hadoop.hive.ql.io.HiveSequenceFileOutputFormat'

LOCATION '/tmp/heartbeat';



ПРОСМОТР ДАННЫХ FLUME

SELECT * FROM heartbeat;



APACHE NIFI



УСТАНОВКА NIFI

Скачиваем и распаковываем дистрибутив:

```
$ wget https://dlcdn.apache.org/nifi/1.15.3/nifi-1.15.3-bin.tar.gz
$ tar xzf nifi-1.15.3-bin.tar.gz
$ rm nifi-1.15.3-bin.tar.gz
$ mv nifi-1.15.3 nifi
```

Задаем необходимые переменные окружения:

```
$ cd nifi
$ export NIFI_HOME=`pwd`
$ export PATH=$PATH:$NIFI_HOME/bin
```

Проверяем работу:

```
$ nifi.sh status
Apache NiFi is not running
```

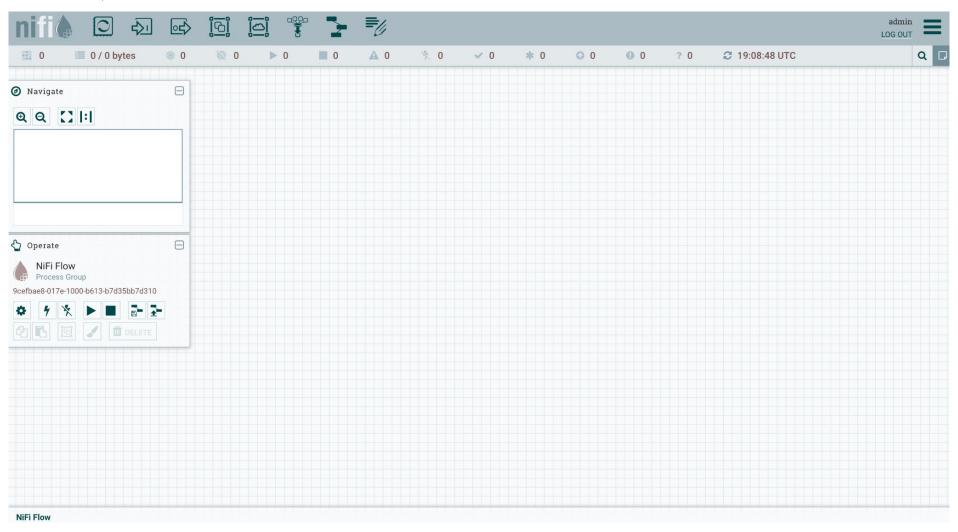


ЗАПУСК NIFI

```
Редактируем конфиг:
    $ vi nifi/conf/nifi.properties
    nifi.web.https.host=0.0.0.0
    nifi.web.https.port=8888
    . . .
Запускаем NiFi:
    $ nifi.sh start
Создаем пользователя:
    $ nifi.sh set-single-user-credentials <login> <password>
Ожидаем окончания старта:
    $ tail -f nifi/logs/nifi-app.log
```

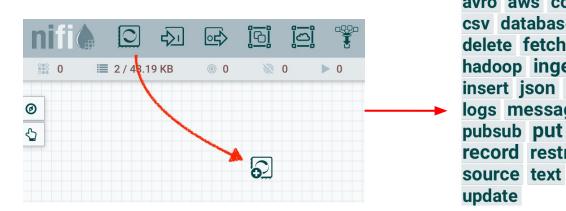


Переходим на https://localhost:8888:

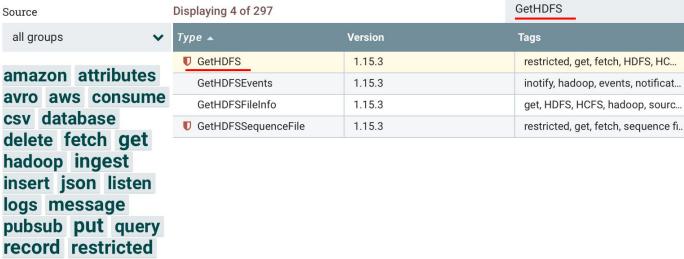




Добавим GetHDFS процессор:



Add Processor

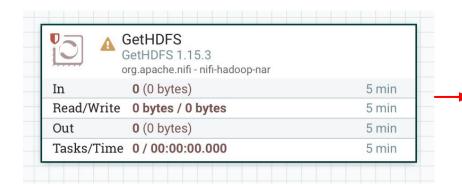


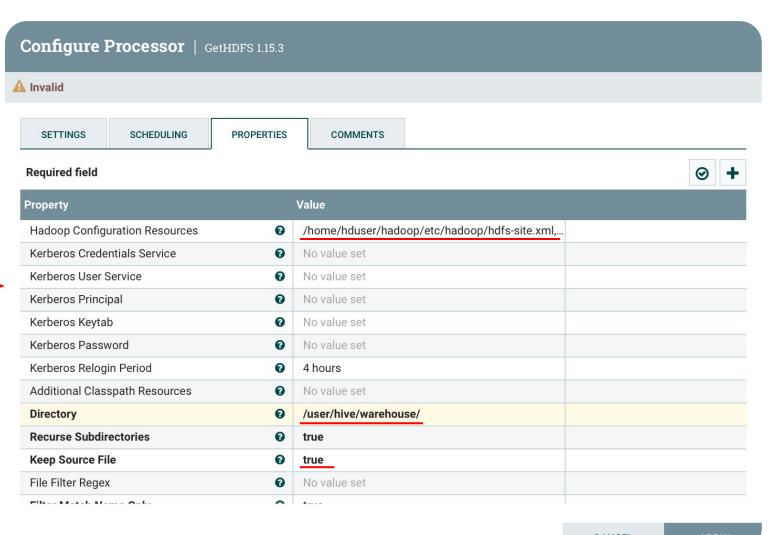
GetHDFS 1.15.3 org.apache.nifi - nifi-hadoop-nar

Fetch files from Hadoop Distributed File System (HDFS) into FlowFiles. This Processor will delete the file from HDFS after fetching it.



Настроим GetHDFS процессор:





CANCEL

APPLY

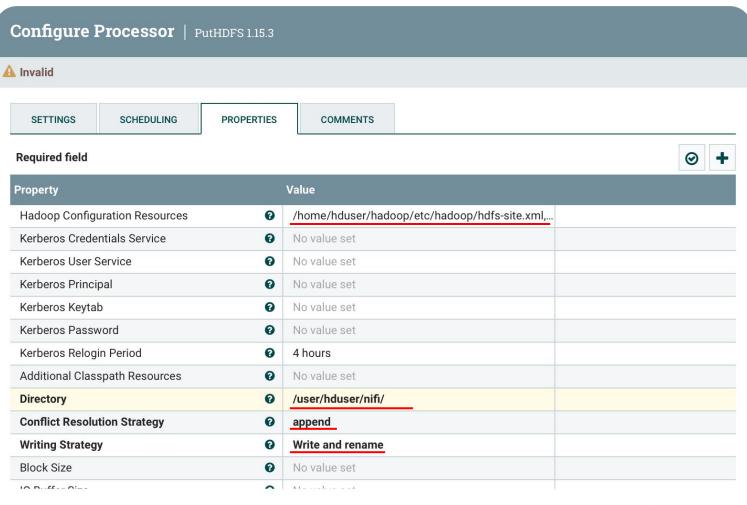


Добавим PutHDFS процессор: Add Processor **PutHDFS** Displaying 1 of 297 Source **∨** Type **△** all groups Version Tags restricted, HDFS, HCFS, hadoop... PutHDFS 1.15.3 amazon attributes avro aws consume csv database 4 delete fetch get hadoop ingest ■ 2 / 48.19 KB 0 insert json listen logs message pubsub put query record restricted source text update PutHDFS 1.15.3 org.apache.nifi - nifi-hadoop-nar Write FlowFile data to Hadoop Distributed File System (HDFS)



Hacтроим PutHDFS процессор:



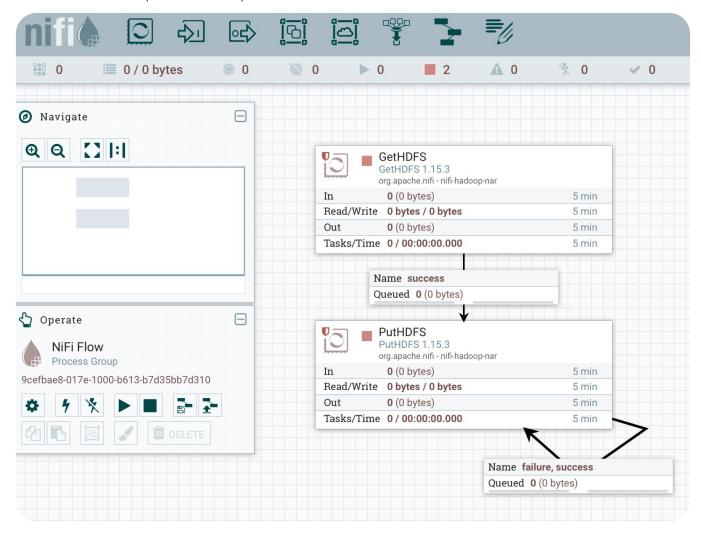


CANCEL

APPLY

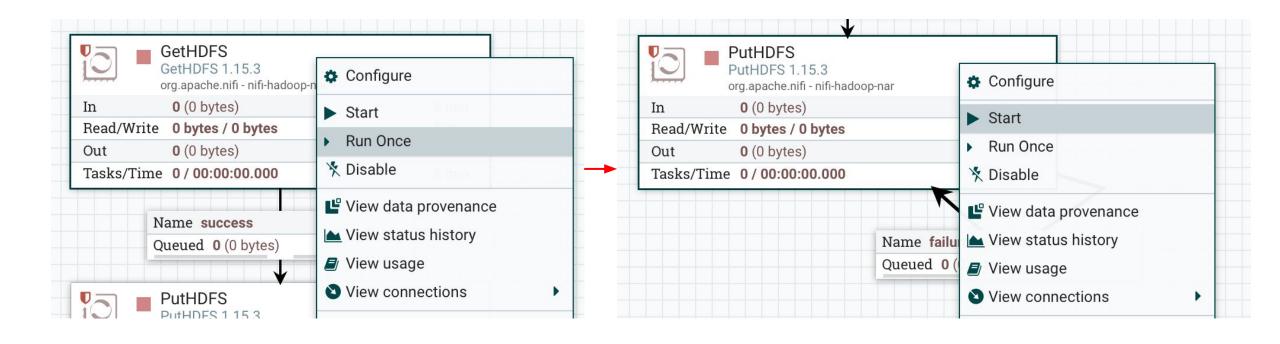


Соеденим GetHDFS и PutHDFS процессоры:





Запустим GetHDFS и PutHDFS процессоры:





После окончания работы в HDFS появилась директория с данными:

hduser@localhost:~\$ hdfs dfs -ls /user/hduser Found 1 items drwxr-xr-x - hduser supergroup 0 2022-01-27 19:44 /user/hduser/nifi



OCTAHOBKA NIFI

Остановим Apache NiFi:

\$ nifi.sh stop

• • •

NiFi has finished shutting down.



ПРАКТИЧЕСКОЕ ЗАДАНИЕ





ПРАКТИЧЕСКОЕ ЗАДАНИЕ

- 1. Установите Apache Sqoop
- 2. Выведите таблицы Hive через JDBC драйвер в Sqoop
- 3. Установите Apache Flume
- 4. Напишите приложение (на bash или python), которое будет периодически писать свои логи или любые другие данные в stdout, после чего настройте сборку этих логов в HDFS через Flume
- 5. Установите Apache NiFi
- 6. Соберите пайплайн в NiFi, который будет читать локальный файл и записывать его в HDFS или наоборот

Спасибо! Каждый день вы становитесь лучше:)

